Nhập môn Khoa học dữ liệu

Bài thực hành số 1: Làm quen với tiền xử lý dữ liệu

1. Thu thập và tiền xử lý dữ liệu

Thu thập và tiền xử lý có vai trò quan trọng ra sao?

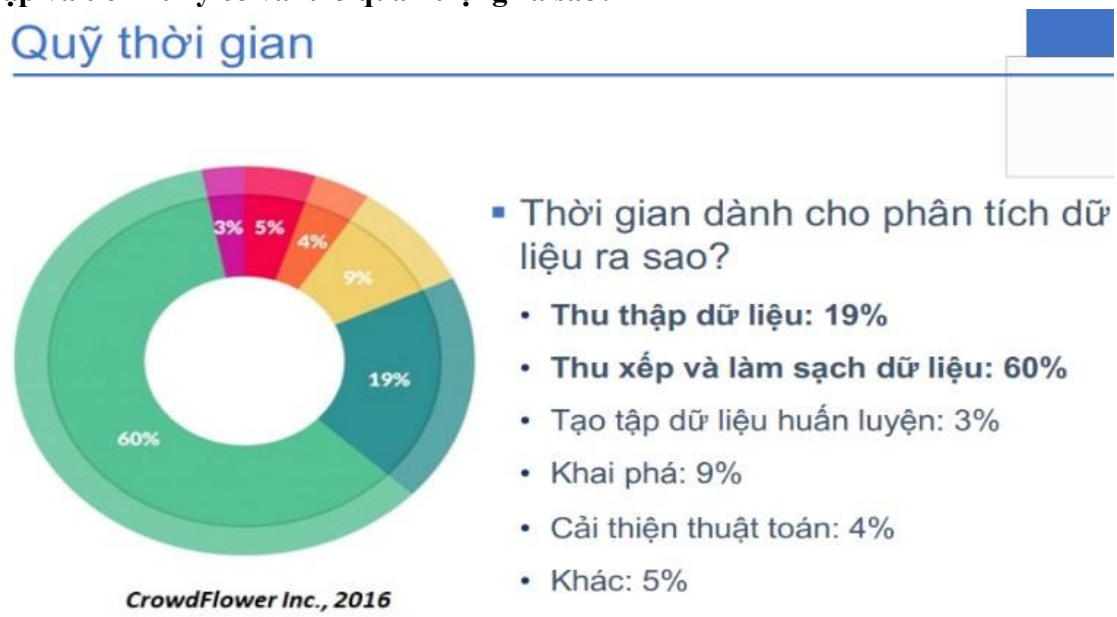

Như vậy, ta thấy việc thu thập và tiền xử lý ở đây tốn rất nhiều thời gian và công sức. **Vậy tiền xử lý dữ liệu (data preprocessing) để làm gì?**

- Thuận tiện trong lưu trữ, truy vấn
- Các mô hình học máy thường làm việc với dữ liệu có cấu trúc: ma trận, vectơ, chuỗi,…
- Học máy thường làm việc hiệu quả nếu có biểu diễn dữ liệu phù hợp

Ta phải làm những gì trong bước tiền xử lý dữ liệu?

- Thu thập dữ liệu
  - Lấy mẫu (sampling)
  - **Kỹ thuật: crawling, logging, scraping**
- Xử lý dữ liệu
  - Lọc nhiễu, làm sạch, số hoá,…

2. Hướng dẫn cài đặt môi trường (Miniconda và Colab, các bạn chọn 1 trong 2 môi trường để thực hành)

2.1 Cài đặt Miniconda

Miniconda là một nền tảng nhẹ hơn của Anaconda bao gồm các công cụ phục vụ cho trí tuệ nhân tạo và học máy. Miniconda hoàn toàn miễn phí và dễ sử dụng. **Cấu hình khuyến nghị** * Máy tính chạy từ Windows 10 trở lên * Có quyền admin

3. Hướng dẫn thiết lập Google Colab

Bước 1: Truy cập link sau để tải notebook và upload lên Drive

Bước 2: Thực hiện các bước trong phần Chuẩn bị môi trường và dữ liệu bên dưới

3.1 Chuẩn bị môi trường và dữ liệu

Bước 1: Ta thực hiện tải file code phục vụ cho bài học theo nguồn dưới đây

Bước 2: Cài đặt thư viện

```
!pip install pandas numpy matplotlib scipy scikit-image seaborn scikit-learn jupyterlab beautifulsoup4 PyYAML pyvi
```

Bước 3: Upload file drug200.csv trong thư mục data đã tải ở bước 1.

```
from google.colab import files
uploaded = files.upload()
```

3.2 Tiền xử lý dữ liệu cho dữ liệu về loại thuốc phản ứng của người bệnh

3.2.1 Nội dung thực hành

1. Giới thiệu về dữ liệu
2. Tiền xử lý dữ liệu

3.2.1.1 Giới thiệu về dữ liệu

Giả sử bạn là một người nghiên cứu về dữ liệu y học, bạn đã thu thập được một tập dữ liệu các bệnh nhân của cùng một loại bệnh, trong khi điều trị mỗi bệnh nhân phản ứng với 1 trong 5 loại thuốc A, B, C, X và Y.

Công việc cần làm là xây dựng một mô hình nhằm tìm ra loại thuốc phù hợp cho bệnh nhân mới bị mắc loại bệnh trên. Các trường dữ liệu gồm có:

```
-  Age
-  Sex
-  Blood Pressure: huyết áp (High, Low, Normal)
-  Cholesterol: hàm lượng cholesterol (Normal, High)
-  Na_to_K: hàm lượng natri và kali trong cơ thể
```

```
-  Drug: drugA, drugB, drugC, drugX, drugY
```

Đọc dữ liệu

Trước khi huấn luyện Random Forest (hoặc bất kỳ mô hình nào), ta cần tiến hành tiền xử lý để đưa dữ liệu về dạng mà mô hình có thể hiểu được

```
import pandas as pd
my_data = pd.read_csv("")#TODO: Điền đường dẫn file drug.csv đã tải về ở
bước trên
 #TODO: In 20 record đầu tiên
```

Trong tập dữ liệu:

Age → số (numeric), dùng trực tiếp.

Na_to_K → số thực (float), dùng trực tiếp.

Sex → phân loại nhị phân (M/F).

BP (Blood Pressure) → phân loại 3 giá trị (HIGH, NORMAL, LOW).

Cholesterol → phân loại 2 giá trị (NORMAL, HIGH).

Drug → nhãn mục tiêu (target: drugA, drugB, drugC, drugX, drugY).

```
my_data.shape # (x, y): x records, y trường dữ liệu
```

3.1.1.2 Tiền xử lý dữ liệu

a) Làm sạch dữ liệu

Kiểm tra & khảo sát dữ liệu (Inspect & audit schema)

Đây là bước đầu tiên, giống như đi khám tổng quát trước khi chữa bệnh. Ta cần biết dữ liệu có bao nhiêu dòng, bao nhiêu cột, kiểu dữ liệu của từng cột là gì (số, chữ, ngày tháng...). Đồng thời, xem thử vài dòng đầu để hình dung cấu trúc. Việc này giúp phát hiện sớm các vấn đề: có cột nào bị thiếu nhiều giá trị không, có kiểu dữ liệu nào sai (ví dụ ngày tháng bị ghi thành chữ), hay có con số nào bất thường.

Xử lý giá trị thiếu (Handle missing values)

Trong dữ liệu thực tế, hiếm khi tất cả đều đầy đủ. Có thể bệnh nhân chưa làm xét nghiệm, khách hàng bỏ trống số điện thoại... Những ô bị trống này gọi là giá trị thiếu. Nếu giữ nguyên, khi phân tích sẽ dễ sai hoặc thậm chí không chạy được. Vì vậy, ta cần xử lý:

Với cột số, có thể điền bằng trung bình hoặc trung vị để gần với thực tế.

Với cột chữ, có thể điền bằng giá trị xuất hiện nhiều nhất.

Nếu một cột quá nhiều giá trị bị thiếu (ví dụ 90% trống), đôi khi nên loại bỏ.

Loại bỏ trùng lặp (Remove duplicates)

Một lỗi thường gặp là dữ liệu bị nhập trùng. Ví dụ: một bệnh nhân được ghi tên hai lần, hay một đơn hàng bị lưu lại 2 bản. Nếu không xử lý, phân tích sẽ bị sai lệch: một người tính thành hai, một sản phẩm tính thành hai lần bán. Vì vậy, cần phát hiện và xoá các dòng dữ liệu giống hệt nhau, để đảm bảo mỗi bản ghi trong dataset là duy nhất.

b) Chuẩn hóa dữ liệu

Tách dữ liệu:

- X là Ma trận thuộc tính (bao gồm 5 trường thuộc tính đã nêu ở trên)
- y là Vector thuốc phản hồi (gồm trường thuộc tính drug)

Các thuật toán ML (hồi quy tuyến tính, logistic, SVM, neural network, …) đều dựa trên các phép toán đại số tuyến tính, giải tích (nhân ma trận, đạo hàm, tính gradient…). Như vậy các giá trị dạng categorical trong các trường dữ liệu BP, Cloresterol và Sex cần phải được xử lý trước. Ta sử dụng phương pháp gọi là One-hot encoding và Ordinal Encoding để xử lý dữ liệu dạng categorical.

Sau khi đã thực hành xong, các bạn trả lời những câu hỏi sau để củng cố lại kiến thức:

1. Tiền xử lý dữ liệu là gì? Tại sao ta phải tiền xử lý dữ liệu?

2. Mô tả các tham số được sử dụng ở hàm read_csv của Pandas trong bài học hôm nay.

3. Như các bạn đã thấy ở bước chuẩn hoá các thuộc tính Age, Na_to_K là các số thực, ta thực hiện xử lý bằng cách đưa về phân phối chuẩn sử dụng lớp StandardScaler() trong scikit-learn. Tại sao ta lại phải làm như vậy?

4. Mô tả phương pháp Ordinal Encoding và One-hot Encoding đã được sử dụng để xử lý dữ liệu dang categorical trong các trường thuộc tính Sex, BP?